

Predicción de aprobación de créditos bancarios mediante modelos de aprendizaje automático

David Arango Pineda, Sara Galván Ortega y Juan Pablo Ramos Velez

*Departamento de Ingeniería de sistemas, Facultad de Ingeniería
Universidad de Antioquia UdeA*

Calle 70 No. 52-21, A.A. 1226, Medellín, Colombia

Email: {david.arango, sara.galvan, juanpablo.ramos}@udea.edu.co

Resumen—La aprobación de créditos bancarios representa un desafío importante para las entidades financieras debido al riesgo asociado al incumplimiento de pago por parte de los clientes. En este trabajo se presenta un análisis comparativo de modelos de aprendizaje automático aplicados a la predicción de aprobación de créditos utilizando el conjunto de datos *Loan Prediction Problem*. El estudio contempla etapas de análisis exploratorio, tratamiento de valores faltantes, manejo de desbalance de clases mediante ponderación de clases, ajuste de hiperparámetros y reducción de dimensión. Se compararon siete modelos: Regresión Logística, máquinas de soporte vectorial (SVM), árboles de decisión, Random Forest, K-Nearest Neighbors (KNN), XGBoost y una red neuronal artificial (MLP), evaluados mediante validación cruzada estratificada con intervalos de confianza. Los resultados muestran que SVM obtuvo el mejor desempeño ($F_1 = 0,903$ en test), aunque las diferencias entre los modelos no fueron estadísticamente significativas. La reducción de dimensión mediante PCA conservó el desempeño del mejor modelo con una reducción del 21,4 % de las variables, mientras que la reducción no lineal con UMAP lo degradó. Se concluye que la estructura discriminante del problema es esencialmente lineal y está fuertemente dominada por la variable de historial crediticio.

Index Terms—aprendizaje automático, aprobación de créditos, clasificación, reducción de dimensión, random forest, máquinas de soporte vectorial, XGBoost

I. INTRODUCCIÓN

EN la actualidad, las entidades financieras dependen ampliamente de los préstamos bancarios como una de sus principales fuentes de ingresos. Sin embargo, el incremento constante en las solicitudes de crédito ha aumentado el riesgo asociado al incumplimiento de pago por parte de los clientes. Determinar si un solicitante posee la capacidad financiera para cumplir con sus obligaciones representa una tarea compleja debido a la gran cantidad de variables económicas y demográficas involucradas en el proceso de evaluación crediticia [1], [2].

Tradicionalmente, las decisiones relacionadas con la aprobación de créditos han sido realizadas mediante análisis manuales apoyados en criterios definidos por expertos financieros. No obstante, el crecimiento en la disponibilidad de datos y el avance de las técnicas de aprendizaje automático han impulsado el desarrollo de sistemas automatizados capaces de identificar patrones relevantes en historiales financieros y perfiles demográficos.

Diversos estudios han demostrado que algoritmos como máquinas de soporte vectorial (SVM), Random Forest, árboles

de decisión y XGBoost pueden obtener resultados competitivos en tareas de predicción financiera. Sin embargo, factores como la presencia de valores faltantes, el desbalance de clases y la selección de características continúan representando desafíos importantes para la construcción de modelos robustos y generalizables.

Aunque algunos trabajos reportan altos niveles de exactitud, pocos estudios analizan el impacto de las técnicas de selección de características en escenarios con desbalance de clases y conjuntos de datos de tamaño reducido.

A diferencia de trabajos previos centrados únicamente en la comparación de clasificadores, este estudio propone un análisis metodológico orientado a evaluar el impacto de técnicas de preprocesamiento, manejo de desbalance y reducción de dimensión sobre el desempeño de modelos predictivos para aprobación de créditos bancarios.

El objetivo principal consiste en establecer una metodología de evaluación para comparar diferentes algoritmos de clasificación y analizar el efecto de las estrategias de reducción de dimensión sobre el desempeño predictivo.

II. ESTADO DEL ARTE

Diversos estudios han abordado el problema de aprobación de créditos bancarios utilizando técnicas de aprendizaje automático y modelos de clasificación supervisada. En la mayoría de los casos, el objetivo consiste en determinar si un solicitante es apto o no para recibir un préstamo bancario a partir de variables financieras y demográficas.

Mounagurusamy et al. [3] realizaron una comparación entre algoritmos como K-Nearest Neighbors (KNN), Regresión Logística, árboles de decisión y Random Forest utilizando información obtenida desde Kaggle. Los autores reportaron que KNN alcanzó el mejor desempeño utilizando exactitud como métrica principal.

Posteriormente, Sheikh et al. [4] propusieron un modelo basado en Regresión Logística para clasificar clientes elegibles y no elegibles para créditos bancarios. El estudio resaltó la importancia del historial crediticio y de variables económicas relacionadas con ingresos y duración del préstamo.

De manera similar, Tumuluru et al. [1] compararon Random Forest, SVM, Regresión Logística y KNN utilizando métricas de exactitud para evaluar el desempeño de los modelos. Los resultados mostraron que Random Forest obtuvo el mejor comportamiento debido a su capacidad para modelar relaciones no lineales entre variables financieras y demográficas.

Más recientemente, Saha et al. [5] desarrollaron un marco de aprendizaje automático orientado a mejorar la precisión y robustez de sistemas automáticos de aprobación de créditos. En este estudio se compararon modelos como Regresión Logística, árboles de decisión, Random Forest, SVM, Ensemble Bagged Tree y XGBoost. Los resultados mostraron que los métodos basados en ensamblajes, particularmente XGBoost, alcanzaron los mejores resultados en exactitud, precisión y puntaje F1.

En esta misma línea, Ahosanul Haque et al. [2] aplicaron diversas técnicas de aprendizaje automático para la predicción de préstamos bancarios, enfatizando la importancia del tratamiento de valores faltantes y del manejo del desbalance de clases como etapas determinantes en el desempeño final de los modelos.

Los antecedentes revisados evidencian que los métodos basados en ensamblajes y árboles de decisión presentan resultados competitivos en problemas de clasificación crediticia. Sin embargo, continúa existiendo interés en analizar el impacto de estrategias de preprocesamiento y reducción de dimensión sobre el rendimiento predictivo de los modelos, especialmente en conjuntos de datos con desbalance de clases y valores faltantes.

III. MÉTODO PROPUESTO

A. Conjunto de datos

El conjunto de datos utilizado corresponde al problema *Loan Prediction Problem*, disponible públicamente en Kaggle. El archivo de entrenamiento contiene 614 registros y 13 columnas: un identificador (*Loan_ID*), 11 variables predictoras y la variable objetivo *Loan_Status*. El archivo de prueba provisto por la plataforma no incluye la variable objetivo, por lo que la evaluación de desempeño se realizó particionando el conjunto etiquetado. La Tabla I describe las variables que componen el conjunto de datos.

La variable *Credit_History* es binaria e indica si el historial crediticio del solicitante cumple con las pautas establecidas por la entidad.

Durante el análisis exploratorio inicial se identificó la presencia de valores faltantes en diferentes variables, principalmente en *Credit_History* (50), *Self_Employed* (32) y *LoanAmount* (22). Adicionalmente, se observó un marcado desbalance de clases en la variable objetivo, donde la cantidad de préstamos aprobados (68,7 %) supera considerablemente la cantidad de préstamos rechazados (31,3 %).

B. Preprocesamiento

Se eliminó la variable identificadora *Loan_ID* por carecer de valor predictivo. Para el manejo de valores faltantes se aplicó imputación por moda en variables categóricas y por mediana en variables numéricas, esta última por su robustez frente a valores atípicos.

Las variables categóricas fueron transformadas mediante codificación *One-Hot* (eliminando la primera categoría para evitar multicolinealidad), mientras que las variables numéricas fueron estandarizadas para mejorar el desempeño de algoritmos sensibles a la magnitud de los datos, como SVM, KNN y

Tabla I
DESCRIPCIÓN DE LAS VARIABLES DEL CONJUNTO DE DATOS

Variable	Tipo	Descripción
<i>Loan_ID</i> ^a	Identif.	Código único de la solicitud
<i>Gender</i>	Categórica	Género del solicitante
<i>Married</i>	Categórica	Estado civil
<i>Dependents</i>	Categórica	Número de dependientes (0, 1, 2, 3+)
<i>Education</i>	Categórica	Nivel educativo (graduado / no graduado)
<i>Self_Employed</i>	Categórica	Trabaja por cuenta propia
<i>ApplicantIncome</i>	Númerica	Ingreso del solicitante
<i>CoapplicantIncome</i>	Númerica	Ingreso del codeudor
<i>LoanAmount</i>	Númerica	Monto del préstamo solicitado
<i>Loan_Amount_Term</i>	Númerica	Plazo del préstamo (meses)
<i>Credit_History</i>	Binaria	Cumplimiento de las pautas crediticias
<i>Property_Area</i>	Categórica	Zona de la propiedad (urbana, semiurbana, rural)
<i>Loan_Status</i> ^b	Binaria	Aprobación del crédito (Y/N)

^a Eliminada en el preprocesamiento por carecer de valor predictivo.

^b Variable objetivo.

la red neuronal. Tras esta codificación, las 11 variables predictoras originales se expandieron a 14 columnas, que constituyen el espacio de características empleado en el entrenamiento. La imputación y el escalamiento se realizaron dentro de un *pipeline* ajustado independientemente en cada partición de la validación cruzada, evitando así la fuga de información.

Debido al desbalance presente en la variable objetivo, se empleó la ponderación de clases (*class_weight balanced*, y *scale_pos_weight* en XGBoost) para reducir el sesgo hacia la clase mayoritaria, evitando la dependencia de técnicas de sobremuestreo.

C. Modelos de clasificación

Se compararon siete modelos que cubren los principales paradigmas de aprendizaje supervisado:

- Regresión Logística (modelo paramétrico)
- K-Nearest Neighbors, KNN (modelo no paramétrico)
- Árbol de Decisión
- Random Forest (ensamble por *bagging*)
- XGBoost (ensamble por *boosting*)
- Máquina de soporte vectorial, SVM
- Red neuronal artificial, perceptrón multicapa (MLP)

Los algoritmos fueron seleccionados por su amplio uso en problemas de clasificación financiera y por los resultados reportados en trabajos previos. La Tabla II resume las ventajas y limitaciones de cada uno.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

A. Configuración experimental

El conjunto etiquetado se dividió en un 80 % para desarrollo y un 20 % para prueba, mediante partición estratificada para preservar la proporción de clases. El ajuste de hiperparámetros se realizó mediante búsqueda exhaustiva (*GridSearchCV*)

Tabla II
COMPARACIÓN GENERAL DE MODELOS DE CLASIFICACIÓN

Modelo	Ventaja principal	Limitación principal
Regresión Logística	Interpretabilidad y simplicidad	Limitaciones frente a relaciones no lineales
SVM	Buena capacidad de generalización	Sensible al escalamiento y costo computacional
Árboles de decisión	Interpretabilidad y facilidad de implementación	Riesgo de sobreajuste
Random Forest	Robustez y reducción de sobreajuste	Mayor complejidad computacional
KNN	Implementación sencilla	Sensible a ruido y escalamiento
XGBoost	Alto desempeño predictivo	Ajuste de hiperparámetros más complejo
MLP	Captura relaciones no lineales	Requiere más datos y ajuste cuidadoso

con validación cruzada estratificada de 10 pliegues sobre el conjunto de desarrollo, optimizando el puntaje F_1 por su adecuación frente al desbalance de clases. El conjunto de prueba se mantuvo aislado hasta la evaluación final.

La Tabla III presenta la malla de hiperparámetros explorada para cada modelo.

Tabla III
MALLA DE HIPERPARÁMETROS EVALUADA POR MODELO

Modelo	Hiperparámetros (malla)
Regresión Logística	$C \in \{0,01; 0,1; 0,5; 1; 5; 10\}$
KNN	$n_neighbors \in \{3, 5, 7, 9, 11, 15, 21\}$; $weights \in \{uniform, distance\}$
Árbol de Decisión	$max_depth \in \{3, 5, 7, 10, None\}$; $min_samples_leaf \in \{1, 5, 10, 20\}$; $criterion \in \{gini, entropy\}$
Random Forest	$n_estimators \in \{100, 200, 300\}$; $max_depth \in \{5, 10, None\}$; $min_samples_leaf \in \{1, 5, 10\}$
XGBoost	$n_estimators \in \{100, 200\}$; $max_depth \in \{3, 5, 7\}$; $learning_rate \in \{0,01; 0,1; 0,3\}$
SVM	$C \in \{0,1; 1; 10\}$; $kernel \in \{linear, rbf\}$; $gamma \in \{scale, 0,01, 0,1\}$
MLP	$hidden_layer_sizes \in \{(32), (64), (64, 32)\}$; $\alpha \in \{10^{-4}, 10^{-3}, 10^{-2}\}$

B. Métricas de evaluación

El desempeño se evaluó mediante exactitud, precisión, sensibilidad (*recall*), puntaje F_1 y AUC-ROC, definidas en las Ecuaciones (1)–(4). La precisión y la sensibilidad se expresan como:

$$\text{Precisión} = \frac{VP}{VP + FP} \quad (1)$$

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \quad (2)$$

donde VP , FP y FN corresponden a verdaderos positivos, falsos positivos y falsos negativos, respectivamente. El puntaje F_1 se define como la media armónica entre precisión y sensibilidad, lo que lo hace especialmente adecuado ante el desbalance de clases:




Figura 1. Regresión Logística: efecto del parámetro de regularización C sobre el F_1 de entrenamiento y validación. Se muestra como ejemplo representativo del comportamiento observado en todos los modelos.

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad (3)$$

La exactitud mide la proporción de aciertos totales:

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN} \quad (4)$$

donde VN representa los verdaderos negativos. El uso de múltiples métricas permite analizar el comportamiento de los modelos desde diferentes perspectivas, lo cual resulta especialmente relevante dado el desbalance de la variable objetivo, donde la exactitud por sí sola puede resultar engañosa.

Adicionalmente, los resultados de validación cruzada se reportan con su intervalo de confianza al 95 %, estimado a partir de los $k = 10$ pliegues según la Ecuación (5):

$$IC_{95\%} = \bar{x} \pm 1,96 \cdot \frac{s}{\sqrt{k}} \quad (5)$$

donde $\bar{x}$ es la media de la métrica sobre los pliegues y s su desviación estándar.

C. Resultados del entrenamiento

El efecto de los hiperparámetros sobre el desempeño mostró una tendencia consistente en todos los modelos: las configuraciones más regularizadas o simples ofrecieron mejor capacidad de generalización. A modo de ejemplo, en la Regresión Logística (Figura 1) el mejor desempeño se obtuvo con regularización fuerte ($C = 0,01$), manteniéndose las curvas de entrenamiento y validación próximas, lo que indica ausencia de sobreajuste. De forma análoga, el Árbol de Decisión alcanzó su máximo con profundidad reducida ($max_depth = 3$), degradándose al aumentar la complejidad, y XGBoost presentó mejor desempeño con una tasa de aprendizaje baja (0,01).

La Tabla IV presenta los resultados de validación cruzada con sus intervalos de confianza al 95 %, y la Tabla V los resultados sobre el conjunto de prueba. La Figura 2 resume gráficamente la comparación por F_1 .

SVM obtuvo el mejor desempeño tanto en validación ($F_1 = 0,870$) como en prueba ($F_1 = 0,903$), seguido muy de cerca por Random Forest y XGBoost ($F_1 = 0,857$ en validación). No obstante, como se observa en la Figura 2, los intervalos

Tabla IV
RESULTADOS DE VALIDACIÓN CRUZADA (MEDIA $\pm$ INTERVALO DE CONFIANZA AL 95 %)

Modelo	Exactitud	Precisión	Sensibilidad	F_1	AUC-ROC
Regresión Logística	0,752 $\pm$ 0,030	0,781 $\pm$ 0,028	0,893 $\pm$ 0,032	0,832 $\pm$ 0,019	0,737 $\pm$ 0,074
KNN	0,774 $\pm$ 0,033	0,763 $\pm$ 0,025	0,976 $\pm$ 0,019	0,856 $\pm$ 0,020	0,688 $\pm$ 0,067
Árbol de Decisión	0,753 $\pm$ 0,045	0,774 $\pm$ 0,026	0,908 $\pm$ 0,068	0,833 $\pm$ 0,038	0,694 $\pm$ 0,055
Random Forest	0,782 $\pm$ 0,032	0,783 $\pm$ 0,027	0,950 $\pm$ 0,019	0,857 $\pm$ 0,019	0,744 $\pm$ 0,063
XGBoost	0,782 $\pm$ 0,029	0,783 $\pm$ 0,026	0,950 $\pm$ 0,017	0,857 $\pm$ 0,017	0,736 $\pm$ 0,065
SVM	0,798 $\pm$ 0,033	0,782 $\pm$ 0,027	0,982 $\pm$ 0,016	0,870 $\pm$ 0,019	0,708 $\pm$ 0,068
Red Neuronal (MLP)	0,764 $\pm$ 0,038	0,757 $\pm$ 0,031	0,970 $\pm$ 0,019	0,850 $\pm$ 0,023	0,691 $\pm$ 0,077

Tabla V
RESULTADOS SOBRE EL CONJUNTO DE PRUEBA RETENIDO (20 %)

Modelo	Exactitud	Precisión	Sensibilidad	F_1	AUC-ROC
SVM	0,854	0,832	0,988	0,903	0,801
XGBoost	0,854	0,838	0,976	0,902	0,812
Red Neuronal (MLP)	0,837	0,816	0,988	0,894	0,794
Regresión Logística	0,846	0,859	0,929	0,893	0,840
KNN	0,829	0,808	0,988	0,889	0,812
Random Forest	0,821	0,839	0,918	0,876	0,814
Árbol de Decisión	0,772	0,828	0,847	0,837	0,773




Figura 2. Comparación de modelos por F_1 en validación cruzada con intervalos de confianza al 95 %. El solapamiento de los intervalos indica que las diferencias entre modelos no son estadísticamente significativas.

de confianza de los modelos se solapan ampliamente, por lo que las diferencias de desempeño no son estadísticamente significativas. Las curvas ROC de los siete modelos sobre el conjunto de prueba (Figura 3) confirman esta observación: las curvas se mantienen próximas entre sí, con valores de AUC en un rango estrecho ($\approx 0,77$ – $0,84$).

Un patrón consistente en todos los modelos es la elevada sensibilidad (*recall* entre 0,85 y 0,99) frente a una precisión más moderada, lo que indica una tendencia a aprobar préstamos: los modelos rara vez rechazan solicitudes que debían aprobarse, pero aprueban una fracción considerable de las que debían rechazarse. Este comportamiento se confirma en la matriz de confusión del mejor modelo (Figura 4): de los préstamos efectivamente aprobados, el SVM detecta casi la totalidad (solo un falso negativo), pero clasifica erróneamente como aprobados a cerca de la mitad de los que debían rechazarse.

Conviene destacar la brecha entre el F_1 ($\approx 0,90$) y el AUC-ROC ($\approx 0,80$). El F_1 se evalúa en el umbral de decisión




Figura 3. Curvas ROC de los siete modelos sobre el conjunto de prueba. La proximidad entre las curvas refuerza que las diferencias de desempeño entre modelos son reducidas.

por defecto, donde la clase mayoritaria (aprobados) favorece valores altos; en cambio, el AUC mide la capacidad de separación del modelo a lo largo de todos los umbrales posibles, reflejando que distinguir limpiamente los rechazos resulta más difícil. Esta diferencia es coherente con el desbalance de clases y con el sesgo de los modelos hacia la clase mayoritaria, y advierte que un F_1 elevado no implica necesariamente una separación óptima entre clases.

Para cuantificar este sesgo más allá del F_1 —que pondera implícitamente la clase mayoritaria—, la Tabla VI reporta dos métricas que tratan ambas clases con igual peso: el F_1 -macro (promedio no ponderado del F_1 de cada clase) y la exactitud balanceada (promedio de la sensibilidad por clase). Estas mé-




Figura 4. Matriz de confusión del modelo SVM sobre el conjunto de prueba. El modelo prioriza la detección de préstamos aprobados a costa de una mayor tasa de falsos positivos.

tricas se calcularon sobre la validación cruzada —y no sobre el conjunto de prueba— para que sean directamente comparables con los valores de la Tabla IV y reflejen el comportamiento promedio de cada modelo en los diez pliegues, evitando las conclusiones que podrían extraerse de una única partición de test; la matriz de confusión (Figura 4) ilustra el mismo fenómeno de forma concreta sobre el test retenido. Bajo estas métricas, el desempeño de todos los modelos cae a un rango estrecho ($\approx 0,65$ – $0,68$), muy por debajo del F_1 convencional ($\approx 0,82$ – $0,86$). Esta caída evidencia que el desempeño elevado observado en la Tabla IV se explica en gran medida por el acierto sobre la clase mayoritaria (aprobados), mientras que la detección de la clase minoritaria (rechazos) —la de mayor interés para la entidad— es considerablemente más débil. El resultado refuerza la lectura crítica de los demás indicadores: bajo un criterio que penaliza por igual ambos tipos de error, la ventaja del mejor modelo se diluye y ningún clasificador resulta claramente superior.

Tabla VI
MÉTRICAS EQUILIBRADAS EN VALIDACIÓN CRUZADA (MEDIA $\pm$ IC AL 95 %)

Modelo	F_1 -macro	Exactitud balanceada
Regresión Logística	$0,672 \pm 0,054$	$0,668 \pm 0,044$
KNN	$0,648 \pm 0,056$	$0,644 \pm 0,042$
Árbol de Decisión	$0,671 \pm 0,049$	$0,667 \pm 0,043$
Random Forest	$0,659 \pm 0,051$	$0,657 \pm 0,041$
XGBoost	$0,683 \pm 0,057$	$0,674 \pm 0,044$
SVM	$0,669 \pm 0,037$	$0,665 \pm 0,035$
Red Neuronal (MLP)	$0,682 \pm 0,035$	$0,676 \pm 0,033$

V. REDUCCIÓN DE DIMENSIÓN

En esta fase se evaluó la posibilidad de reducir la complejidad del modelo final mediante el análisis individual de variables y dos técnicas de extracción de características: PCA (lineal) y UMAP (no lineal). Los dos mejores modelos se seleccionaron según su puntaje F_1 en validación cruzada —no sobre el conjunto de prueba, que se reservó exclusivamente




Figura 5. Correlación de cada variable con la variable objetivo *Loan_Status*.

para la evaluación final—, resultando en SVM y Random Forest. Las técnicas de extracción se reevaluaron sobre ambos modelos.

A. Análisis individual de variables

Se analizó la correlación de cada variable con la variable objetivo (Figura 5) y la correlación entre predictoras (Figura 6). La variable *Credit_History* presentó la mayor correlación con el objetivo ($\approx 0,54$), muy por encima del resto de variables. A considerable distancia le siguieron variables relacionadas con la zona de propiedad y el estado civil. En contraste, variables como *Gender*, *Self_Employed* y *ApplicantIncome* mostraron correlación lineal casi nula, posicionándose como candidatas a eliminación. No obstante, dado que la correlación de Pearson solo captura relaciones lineales, variables como *ApplicantIncome* —que mostraron importancia en el modelo Random Forest— deben evaluarse con cautela, pues podrían aportar mediante relaciones no lineales.

La matriz de correlación entre predictoras (Figura 6) no evidenció multicolinealidad significativa; las correlaciones más altas correspondieron a relaciones esperables (ingresos–monto del préstamo) o a artefactos de la codificación *One-Hot*. En particular, *Credit_History* no se correlaciona con otras variables, lo que confirma que su capacidad predictiva representa información no redundante.

B. Extracción de características lineal: PCA

Se aplicó PCA sobre las variables estandarizadas, seleccionando el número de componentes que conserva al menos el 90 % de la varianza acumulada. Este criterio resultó en 11 componentes (Figura 7), equivalente a una reducción del 21,4 % respecto a las 14 variables originales. La curva de varianza acumulada presenta un crecimiento aproximadamente lineal, sin un codo pronunciado, lo que refleja la baja redundancia entre variables observada en el análisis individual: cada componente aporta una fracción similar de información, limitando la capacidad de compresión.




Figura 6. Matriz de correlación entre variables predictoras. La ausencia de correlaciones fuertes indica baja redundancia entre variables.




Figura 7. Varianza explicada acumulada por PCA. Se requieren 11 componentes para conservar el 90 % de la varianza.

El análisis de las cargas (*loadings*) de las componentes reveló un hallazgo relevante: la variable *Credit_History*, pese a ser la de mayor capacidad discriminativa, es una de las que menos contribuye a la varianza total. Esto se debe a que PCA maximiza la varianza de los datos y no su capacidad de separar clases; al tratarse de una variable binaria con baja dispersión, su aporte a las primeras componentes es reducido. Esta observación explica por qué PCA conserva el desempeño pero no lo mejora sustancialmente: las direcciones de máxima varianza no coinciden necesariamente con las de máxima discriminación.

C. Extracción de características no lineal: UMAP

Se aplicó UMAP explorando entre 2 y 5 componentes, seleccionando la configuración con mejor desempeño en validación; ninguna de las configuraciones evaluadas alcanzó el desempeño obtenido con las variables originales ni con PCA. La proyección bidimensional (Figura 8) muestra que las clases aparecen entremezcladas en el espacio reducido, lo que anticipa una pérdida de capacidad discriminante. Esto se debe




Figura 8. Proyección UMAP bidimensional del conjunto de desarrollo. Las clases aprobado (Y) y rechazado (N) aparecen entremezcladas.

a que UMAP preserva la estructura general de vecindad de los datos, pero no necesariamente la separación entre clases, diluyendo la señal de la variable lineal y binaria que domina el problema.

D. Comparación de las técnicas de reducción

La Tabla VII compara el desempeño de los modelos completos frente a las versiones reducidas con PCA y UMAP. La combinación SVM + PCA conservó el desempeño del modelo completo ($F_1 = 0,903$) e incluso mejoró su AUC ($0,801 \rightarrow 0,840$), demostrando que es posible reducir la dimensionalidad sin sacrificar capacidad predictiva. Random Forest presentó un comportamiento similar con PCA, manteniendo un F_1 comparable al del modelo original. En contraste, UMAP, pese a lograr una mayor reducción, degradó notablemente el desempeño de ambos modelos, de forma especialmente acusada en SVM.

Tabla VII
COMPARACIÓN: MODELO ORIGINAL VS. PCA VS. UMAP (CONJUNTO DE PRUEBA)

Modelo	Comp.	Reducción	F_1
SVM (original)	14	0 %	0,903
SVM + PCA	11	21,4 %	0,903
Random Forest (original)	14	0 %	0,876
Random Forest + PCA	11	21,4 %	0,895
Random Forest + UMAP	4	71,4 %	0,829
SVM + UMAP	4	71,4 %	0,533

VI. DISCUSIÓN Y CONCLUSIONES

En este trabajo se desarrolló y evaluó un sistema de predicción de aprobación de créditos bancarios mediante la comparación de siete modelos de aprendizaje automático, complementado con un análisis de reducción de dimensión.

Desempeño de los modelos. Los siete modelos alcanzaron un desempeño competitivo y estadísticamente similar (F_1 entre 0,83 y 0,90 en prueba, con intervalos de confianza solapados), siendo SVM el mejor ($F_1 = 0,903$). No obstante, al evaluar con métricas que ponderan ambas clases por igual (F_1 -macro y exactitud balanceada), el desempeño desciende a un rango de $\approx 0,65$ – $0,68$ y las diferencias entre modelos prácticamente desaparecen, lo que revela que la fortaleza aparente de los modelos se concentra en la clase mayoritaria y que la detección de los rechazos —el caso crítico para la entidad— es limitada. La ponderación de clases mitigó parcialmente el desbalance ($\approx 69\%/31\%$), pero no lo eliminó.

Variable dominante. Tres análisis independientes — correlación, importancia en Random Forest y el comportamiento de los modelos— confirman que *Credit_History* concentra la mayor capacidad discriminativa, coincidiendo con la literatura que resalta el historial crediticio [4]. Este hallazgo merece una lectura cuidadosa: dado que dicha variable indica si el solicitante cumple las pautas crediticias establecidas por la entidad, incorpora implícitamente un juicio previo sobre su solvencia, muy próximo a la decisión que el modelo busca predecir. En consecuencia, el alto desempeño observado se apoya en buena medida en una variable que actúa como aproximación de la decisión final, lo que matiza la interpretación de los resultados: más que descubrir un patrón complejo, los modelos amplifican una señal ya presente en los datos. Esta consideración no invalida los resultados —la información está disponible legítimamente al momento de la evaluación crediticia— pero sí explica por qué modelos simples igualan a los más complejos y por qué el desempeño se concentra en un rango estrecho.

Reducción de dimensión. PCA conservó el 90 % de la varianza con 11 componentes (reducción del 21,4 %) manteniendo el desempeño de los modelos completos, e incluso mejorando el AUC de SVM. La modesta capacidad de reducción refleja la baja redundancia entre variables. Adicionalmente, el análisis de las cargas mostró que la variable más discriminativa (*Credit_History*) contribuye poco a la varianza total, lo que evidencia la diferencia entre varianza y capacidad de discriminación. En contraste, UMAP, pese a lograr mayor compresión, degradó el desempeño. El contraste entre ambas técnicas —PCA conserva, UMAP deteriora— sugiere que la información relevante del problema reside en relaciones de tipo lineal, fácilmente preservadas por proyecciones lineales pero diluidas en transformaciones no lineales.

Comparación con el estado del arte. A diferencia de trabajos previos que reportan a los ensambles como los mejores clasificadores [1], [5], en este estudio SVM igualó o superó a dichos modelos, y las diferencias entre todos los clasificadores fueron mínimas. Esto se atribuye al tamaño reducido del conjunto de datos y al fuerte dominio de una única variable, factores que nivelan el desempeño entre algoritmos.

sobre su origen y proceso de recolección, lo que limita la capacidad de generalización de los modelos. Asimismo, como se discutió previamente, el peso predominante de *Credit_History* condiciona los resultados obtenidos. Estas limitaciones sugieren la conveniencia de validar la metodología sobre conjuntos de datos más amplios y diversos antes de su aplicación en entornos reales.

REFERENCIAS

- [1] P. Tumuluru, L. R. Burra, M. Loukya, S. Bhavana, H. CSaiBaba, and N. Sunanda, “Comparative analysis of customer loan approval prediction using machine learning algorithms,” in *2022 Second International Conference on Artificial Intelligence and Smart Energy (ICAIS)*. IEEE, 2022, pp. 349–353.
- [2] F. Ahosanul Haque, M. Hassan *et al.*, “Bank loan prediction using machine learning techniques,” *arXiv e-prints*, pp. arXiv–2410, 2024.
- [3] M. K. Mounagurusamy, P. Manoharan, J. A. Shathik, A. Pandiaraj, N. Ramshankar *et al.*, “Prediction of loan approval in banks using machine learning algorithm,” in *2024 International Conference on Smart Technologies for Sustainable Development Goals (ICSTSDG)*. IEEE, 2024, pp. 1–6.
- [4] M. A. Sheikh, A. K. Goel, and T. Kumar, “An approach for prediction of loan approval using machine learning algorithm,” in *2020 International Conference on Electronics and Sustainable Communication Systems (ICESC)*. IEEE, 2020, pp. 490–494.
- [5] A. Saha, R. Ranjan, and B. C. Sahana, “Advancement of loan approval system for diverse applicants with machine learning framework,” in *2025 IEEE 14th International Conference on Communication Systems and Network Technologies (CSNT)*. IEEE, 2025, pp. 29–33.

VII. LIMITACIONES

El estudio presenta limitaciones relacionadas con el tamaño reducido del conjunto de datos y el uso de información obtenida desde una plataforma pública, sin información detallada